

Stoneforge RL — Projektdokumentation

Navigation in prozedural generierten Welten mit Reinforcement Learning:
Stand und Entwicklung

Florian Merlau

Laurin

6. Juli 2026

Zusammenfassung

Diese Dokumentation fasst den aktuellen Stand der Projektarbeit zusammen: ein RL-Agent soll in prozedural generierten 2D-Welten (*Stoneforge*) den Exit finden und dabei auf unbekannte Seeds generalisieren. Der beste Agent (RecurrentPPO mit LSTM, Curriculum-Training) erreicht **86 % Success Rate** (stochastisch) auf dem Testset bzw. 68 % auf dem Holdout-Set und übertrifft damit beide Zielkriterien ($\geq 70\%$ / $\geq 60\%$). Dokumentiert werden die Umgebung, die Methodik, die zentrale Ablation (MLP vs. LSTM), der vollständige Entwicklungsverlauf von Projektbeginn bis heute (inkl. negativer Ergebnisse und Root-Cause-Analysen, Quelle: Experiment-Changelog), die Umgebungsrevision v11 vom 06.07.2026 sowie eine Performance-Analyse (CPU vs. Apple-GPU, Batch-Größe), die die Trainingszeit halbiert.

1 Zielsetzung

Gegenstand der Projektarbeit ist die Frage, ob ein Reinforcement-Learning-Agent in prozedural generierten, nur teilweise beobachtbaren 2D-Welten robuste Navigationsstrategien lernen kann, die auf unbekannte Welten (neue Seeds) generalisieren — statt einzelne Karten auswendig zu lernen [1, 2]. Als Erfolgskriterien wurden vorab definiert:

- **Testset A** (Seeds 7000–7049): $\geq 70\%$ Success Rate,
- **Holdout B** (Seeds 8000–8049): $\geq 60\%$ Success Rate,
- pro Konfiguration mindestens 3 Trainingsläufe (Mittelwert $\pm$ Standardabweichung).

2 Die Umgebung Stoneforge

Stoneforge ist ein selbst entwickeltes, rundenbasiertes 2D-Spiel (C++-Kern, Python-Anbindung über pybind11). Die Welt wird pro Seed deterministisch aus Hash-Noise generiert (7 Biome, Chunks à 16×16 Tiles, theoretisch unendlich); der Agent startet bei (0,0) und muss den Exit erreichen.

2.1 POMDP-Charakter

Der Agent sieht nur einen lokalen 15×15 -Ausschnitt der Welt sowie einen *Luftlinien*-Kompass zum Exit — nicht den Weg. Wände, Sackgassen und Umwege außerhalb des Sichtfensters sind unbekannt: Die Aufgabe ist ein *Partially Observable Markov Decision Process* (POMDP). Ohne Gedächtnis ist sie nicht deterministisch lösbar (siehe Ablation in Abschnitt 4).

Bereich	Inhalt	Dim.
Lokales Grid	15×15 Tile-Typen um den Agenten (Sichtradius 7)	225
HP	Lebenspunkte (normiert)	1
Kompass	exitDx, exitDy (Luftlinie, normiert)	2
Episodenfortschritt	Schritt / 4000	1
Gesamt (Env v11)		229

Tabelle 1: Observation der Umgebungsversion v11. Die früheren Features *Energie* und *Inventar* waren im RL-Setup konstant (tote Features) und wurden am 06.07.2026 entfernt (vorher 231 Dimensionen).

2.2 Beobachtung, Aktionen, Episodenende

Der Aktionsraum ist **Discrete(4)**: hoch, runter, links, rechts. Mining, Bauen und Kampf existieren nur im spielbaren Client und sind aus dem RL-Pfad vollständig entfernt. Eine Episode endet bei Erreichen des Exits (Sieg), nach 4000 Schritten (Timeout) oder als Truncation nach 256 Schritten ohne positiven Reward (Early-Stop).

2.3 Reward-Design

Das Reward-Design folgt dem Prinzip: *sparse Primärsignal + theoretisch sauberes dichtes Shaping*. Kernstück ist Potential-Based Reward Shaping (PBRS) auf der BFS-Pfaddistanz zum Exit:

$$F(s, s') = \gamma \Phi(s') - \Phi(s), \quad \Phi(s) = -\frac{d_{\text{BFS}}(s)}{128}, \quad (1)$$

mit $\gamma = 0.999$ (identisch zum RL-Discount) und Gewicht $\beta = 2.5$ (netto ca. +0.01 pro Tile echtem Fortschritt). PBRS ist beweisbar *policy-invariant* — es beschleunigt die Konvergenz, ohne die optimale Politik zu verändern [3]. Entscheidend ist, dass das Potential die *echte* Pfaddistanz (BFS durch Wände gerechnet) verwendet, nicht die Luftlinie: Ein Luftlinien-Potential würde den Agenten systematisch in Sackgassen locken.

Komponente	Wert
Exit erreicht (terminal)	+100
Timeout / Tod (terminal)	−10
PBRS (BFS-Distanz, pro Schritt)	$\approx \pm 0.02$
Explorations-Bonus (neue Tile)	+0.02
Schritt-Penalty	−0.01
2-Schritt-Loop-Penalty	−0.05

Tabelle 2: Reward-Komponenten (Env v11). Der frühere eskalierende Wand-Penalty (−0.05/−0.25) wurde entfernt: Die Summe vieler kleiner Strafen („Straf-Stacking“) machte Erkunden in engen Korridoren unwirtschaftlicher als Stillstand.

2.4 Garantierte Lösbarkeit

Die Exit-Platzierung wählt Kandidaten per Flood-Fill vom Spawn aus ausschließlich über *begehbare* Tiles — jeder mögliche Exit ist damit per Konstruktion erreichbar. Empirisch bestätigt: 3 150 geprüfte Seeds (inkl. aller Eval-Sets und Trainingsbereiche) sowie eine erneute Messung am 05.07.2026 (150/150) ergaben **100 % Lösbarkeit**. Ein BFS-Oracle-Agent erreicht den Exit auf allen Test-Seeds in exakt der BFS-Distanz und bestätigt damit die gesamte Kette aus Weltgenerierung, Bewegungsmechanik und Reward-Signal.

3 Methodik

3.1 Algorithmus

Trainiert wird RecurrentPPO (PPO [4] mit LSTM-Politik [5]) aus *Stable-Baselines3* / *sb3-contrib* [6]. Zentrale Hyperparameter: $n_{\text{steps}} = 256$, $n_{\text{epochs}} = 10$, Lernrate $3 \cdot 10^{-4}$, $\gamma = 0.999$, $\text{ent_coef}=0.05$, LSTM mit 256 Hidden Units (separater Critic-LSTM), 16 parallele Umgebungen.

3.2 Curriculum

Das Training verläuft leistungsbasiert in vier Phasen steigender Exit-Distanz; eine Phase endet, wenn die Ziel-Success-Rate in zwei aufeinanderfolgenden Evaluationen erreicht wird.

Phase	Exit-Distanz	Ziel-SR	Gating-Metrik	ent_coef
1	5–12	85 %	stochastisch	0.05
2	12–25	70 %	stochastisch	0.05
3	25–45 (Eval 35–45)	70 %	deterministisch	0.05 $\rightarrow$ 0.001 (Annealing)
4	25–45 (Greedy Fine-Tune)	60 %	deterministisch	0.0001

Tabelle 3: Curriculum (Stand v11). Phase 1/2 gaten auf der stochastischen SR, da die Politik dort mit $\text{ent_coef}=0.05$ absichtlich nahe-uniform ist und die deterministische SR konstruktionsbedingt kein Signal trägt.

Das Distanz-Curriculum staffelt dabei implizit auch die *Beobachtbarkeit* des Ziels — und damit die Fähigkeit, die je Phase gelernt werden muss. Eine Messung über 200 Welten pro Phase (07.07.2026): In Phase 1 liegt der Exit beim Episodenstart in **72 %** der Welten bereits im 15×15 -Sichtfeld (zu lernen: „geh zum sichtbaren Ziel, weiche lokalen Hindernissen aus“); in Phase 2 nur noch in **6 %** (zu lernen: dem Kompass folgen, Umwege um Hindernisse); in Phase 3 in **0 %** (reine Kompass-Navigation über lange Distanz, inklusive Sackgassen, die nur mit Gedächtnis überwindbar sind). Ein zusätzliches Curriculum über die Sichtfeldgröße — in der Literatur als Übergang von voller zu partieller Beobachtbarkeit beschrieben — wäre daher redundant; zudem wäre es hier riskant, weil ein großes Sichtfeld anfangs eine *reaktive* Strategie ohne Gedächtnisnutzung belohnt, die beim Verkleinern des Fensters wertlos wird (dieselbe Nicht-Übertragbarkeit, die die Ablation in Abschnitt 4 für das BFS-Orakel zeigt).

3.3 Evaluationsprotokoll

Strikte Seed-Trennung: Validierung (6000–6049) steuert Phasenwechsel und Modellauswahl; Testset A (7000–7049) und Holdout B (8000–8049) werden ausschließlich final evaluiert. Ein früherer Data-Leakage-Fehler (Modellauswahl auf den Test-Seeds) wurde identifiziert und behoben. Jede Evaluation misst seit v11 *beide* Betriebsarten: stochastisch (Sampling aus der Politik) und deterministisch (Argmax).

4 Entwicklung und Ergebnisse

4.1 Zentrale Ablation: Gedächtnis schlägt Orakel

Das beste Modell erreicht auf Holdout B 68 % (stochastisch) — beide Zielkriterien sind damit erfüllt. Abbildung 1 zeigt den Trainingsverlauf.

Bedingung	Architektur	BFS in Obs	Curriculum	SR stoch.	SR det.
A (ppo_phase4)	MLP	ja	ja	32 %	0 %
B (ppo_no_bfs)	MLP	nein	nein	—	0 %
C (ppo_lstm_curriculum)	LSTM	nein	ja	86 %	36 %

Tabelle 4: Ablation auf Testset A (Exit 35–45). Der LSTM-Agent ohne BFS-„Orakel“ schlägt den MLP-Agenten mit BFS-Features deutlich — Gedächtnis ist für die POMDP-Navigation wichtiger als zusätzliche Wegweiser-Features.




Abbildung 1: Lernkurve des besten Modells (ppo_lstm_curriculum, Curriculum-Phase 3, stochastische Evaluation auf 50 Seeds).

4.2 Der Det/Stoch-Gap und die POMDP-These

Auffällig ist die Lücke zwischen stochastischer (86 %) und deterministischer (36 %) Evaluation: Die Argmax-Politik folgt dem Luftlinien-Kompass in konkave Wandtaschen und oszilliert dort in 2-Schritt-Schleifen; beim Sampling bricht der Zufall diese Schleifen. Wir interpretieren dies als inhärente Eigenschaft der POMDP-Struktur (der Kompass zeigt durch Wände) in Kombination mit begrenzter LSTM-Kapazität — die stochastische Evaluation ist daher die primäre Metrik, der Gap wird als Limitation ausgewiesen und gezielt adressiert (Ausblick, Abschnitt 9).

4.3 Hyperparameter-Fehleranalyse (v7–v10)

Eine Serie fehlgeschlagener Verbesserungsversuche (v7–v9: Success Rate $\leq 12\%$, `approx_kl` ≈ 0 , `explained_variance` ≈ 0) wurde durch Reverse-Engineering des funktionierenden v2-Modells aufgeklärt:

Parameter	v2 (86 %)	v7–v9 (0–12 %)	Wirkung des Fehlers
ent_coef	0.05	0.01	zu wenig Exploration; Exit wird nie gefunden
n_steps	256	512	BPTT zu lang $\rightarrow$ verschwindende Gradienten
batch_size	8	256	zu wenige Gradient-Updates pro Rollout
Obs-Dimension	231	249	Zusatzfeatures ohne funktionierende Basis

Tabelle 5: Root-Cause-Analyse: `ent_coef` erwies sich als dominanter Faktor. Die Reproduktion der v2-Konfiguration (v10) stellte das Lernen wieder her.

5 Entwicklungsverlauf: Von der Baseline zum LSTM-Agenten

Dieser Abschnitt dokumentiert die Entwicklung des RL-Teils chronologisch von Projektbeginn bis heute. Primärquelle ist das durchgängig geführte Experiment-Changelog (`CHANGELOG.md`), in dem jede Änderung mit Problem, Lösung und Messergebnis festgehalten wurde. Negative Ergebnisse sind bewusst enthalten — sie haben die Architekturentscheidungen maßgeblich geprägt.

5.1 Etappe 1 (Mai 2026): Baselines mit BFS-Orakel

Nach Fertigstellung der Spiel-Engine (Mitte Mai) begann das RL-Training mit Features aus dem BFS-Distanzfeld *in der Observation* (5 Werte: aktuelle Distanz + 4 Nachbarrichtungen) — einem „Orakel“, das dem Agenten die lokal richtige Richtung verriet.

Fehlstart mit DQN: Der erste Agent (DQN) lernte nicht — Diagnose: korrupter Replay-Buffer, 2-Zellen-Oszillationen, und eine Visited-Mask in der Observation (455 Dimensionen), die sich jeden Schritt änderte und den Q-Wert-Argmax destabilisierte. Konsequenz: Wechsel auf PPO, Visited-Mask entfernt.

BFS-Kraftfeld-Bug: Ein Oracle-Test (greedy dem BFS-Feld folgen) scheiterte in 3/3 Seeds — `bfsDistanceAt()` lieferte für Wand-Tiles einen Manhattan-Fallback, wodurch Wände als attraktive Richtung erschienen. Nach dem Fix (Wand $\rightarrow$ 9999): Oracle 3/3. Dieser Test wurde zum Standard-Werkzeug, um Umgebung und Reward von Trainingsproblemen zu trennen.

Curriculum-Lektion: Phase-1-Training (Exit 5–12) erreichte 56 %, aber der naive Transfer auf Phase 2 (12–25) kollabierte (22 % $\rightarrow$ 6 %) — die eingebrennte Kurzdistanz-Politik ließ sich nicht überschreiben. Lösung: Mixed-Distribution-Training (Exit 5–45). Damit erreichte *Phase 3* 86 % stochastisch auf Testset A (drei unabhängige Läufe: $85,3 \pm 3,8$ % auf A, $79,3 \pm 8,1$ % auf B) und *Phase 4* nach Reward-Tuning 98 % (A) / 94 % (B).

Der deterministische Kollaps: Trotz 98 % stochastischer SR lag die Argmax-Auswertung bei 2 %. Die Analyse fand die Wurzel in der Feature-Kodierung: Die BFS-Absolutwerte (/64) unterschieden sich zwischen Nachbarzellen nur um $\approx 0,016$ — zu wenig für eine robuste Richtungspräferenz, und Wände waren durch Clamping nicht von „weit weg“ unterscheidbar (Aliasing). Der Wechsel auf *Delta-Kodierung* (Richtungssignal $\pm 0,5$ statt 0,016, Wand = +1,0) hob die deterministische SR auf 42 % (offene Welt) bzw. 100 % (wanddichte Hard-World); Temperature-Sampling ($\tau = 0,2$) erreichte 100 % bei $\varnothing$ 90 Schritten. Ein Experiment, `exitDx/exitDy` zu entfernen („Phase 5“), scheiterte (max. 40 %) — der Luftlinien-Kompass ist als Fernbereichssignal notwendig.

5.2 Etappe 2 (Juni 2026): Kernbeitrag — Navigation ohne Orakel

Mit funktionierender Baseline wurde die Forschungsfrage geschärft: *Kann der Agent auch ohne BFS-Orakel in der Observation navigieren?* Der Wechsel auf RecurrentPPO (LSTM) mit Curriculum, Explorations-Bonus und `step_frac`-Feature (231-dim Obs, kein BFS) lieferte am 08.06.2026 das zentrale Ergebnis: **86 % stochastisch / 36 % deterministisch** auf Testset A und 68 % / 18 % auf Holdout B — beide Zielkriterien stochastisch erfüllt, erstmals ohne Wegweiser-Orakel (Abbildung 2, Ablation in Tabelle 4). Parallel wurde die POMDP-These formuliert (Abschnitt 4) und, inspiriert vom PokéRL-Projekt, Infrastruktur ergänzt: Seed-Pool (Swarm), WebSocket-Live-Map, Heatmap-Evaluation, Early-Stop-Truncation.

Methodische Härtung (11.06.): Ein Data-Leakage-Fehler wurde entdeckt und behoben — der Trainings-Callback hatte Modellauswahl und Phasenwechsel auf den *Test-Seeds* (7000er) gesteuert; seitdem existiert das getrennte Validierungsset (6000er). Zusätzlich wurde die Lösbarkeit aller relevanten Welten bewiesen (3 150 Seeds, 100 %).




Abbildung 2: Entwicklung über die Modellgenerationen (Testset A, Exit 35–45). Links die MLP-Baselines mit BFS-Orakel in der Observation, rechts der LSTM-Agent ohne Orakel — der Kernbeitrag: nahezu gleiche stochastische Leistung ohne globale Pfadinformation. Der Det/Stoch-Gap zieht sich als zentrales Thema durch alle Generationen.

5.3 Etappe 3 (13.–25.06.): Hyperparameter-Krise und Root-Cause-Analyse

Eine Serie von Verbesserungsversuchen (v6–v9: Wand-Penalty-Entfernung, `visit_count`- und Action-Buffer-Features, diverse Batch-/Epochen-Kombinationen) scheiterte durchgängig (SR 0–12 %, `approx_k1` $\approx$ 0). Die Aufklärung gelang durch *Reverse-Engineering* des letzten funktionierenden Modells (v2): Die zwischenzeitlichen „Optimierungen“ hatten unbemerkt die kritischen Hyperparameter verstellt (Tabelle 5); dominanter Faktor war `ent_coef` (0,05 $\rightarrow$ 0,01: der Agent explorierte nicht mehr genug, um den Exit je zu finden). Die v2-Reproduktion (v10) stellte das Lernen wieder her; der abgeschlossene Lauf vom 25.06. erreichte 86 % (Validierung) nach 2,2 Mio. Steps in 3 h 12 m — das aktuelle Referenzmodell (Abbildung 1).

5.4 Etappe 4 (06.07.2026): Umgebungsrevision v11 und Performance

Ein systematisches Audit (Umgebung, Reward, Trainingspipeline, Usability) führte zu zehn dokumentierten Änderungen — Details in Abschnitt 6 und Abschnitt 7. Höhepunkte: präzise Schwierigkeitssteuerung über BFS-Laufweg, Behebung eines prozess-globalen Config-Lecks (das zuvor unbemerkt die Phase-3-Trainingsverteilung verschob), Entfernung toter Features und Straf-Terme, sowie die validierte Verdopplung der Trainingsgeschwindigkeit (`batch_size` 8 $\rightarrow$ 64, CPU statt GPU).

5.5 Etappe 5 (07.07.2026): Erster v11-Gesamtlauf, Monitoring-Redesign und Seed-Replay-Analyse

Erster v11-Gesamtlauf (Seed 0, laufend). Der erste vollständige Curriculum-Lauf auf der revidierten v11-Umgebung (`models/ppo_lstm_curriculum_v11`) zeigt ein lehrreiches Zwischenbild (Abbildung 3): Phase 1 endete am Step-Limit bei 42 % (stochastisch) — deutlich langsamer als die Batch-Validierung derselben Konfiguration (52 % bereits bei 150k). Die Diagnose im Trainingslog: Die Policy-Updates sind durchgehend gesund (`approx_k1` $\approx$ 0.03, stabile Entropie), aber die `explained_variance` des Critics verharrt bei $\approx$ 0.1 (Validierungslauf: 0.72) — der Lauf ist ein Kandidat für Initialisierungs-Pech und unterstreicht, warum das Protokoll drei Läufe pro Konfiguration verlangt. Bemerkenswert: Direkt nach dem Wechsel in Phase 2 stieg die SR auf 48 % bei größerer Exit-Distanz — die breitere Aufgabenverteilung wirkt als Regularisierer.




Abbildung 3: Lernkurve des ersten v11-Gesamtlaufs (Seed 0, Zwischenstand — der Lauf ist zum Redaktionszeitpunkt in Phase 3). Seit v11 misst jeder Eval-Checkpoint beide Betriebsarten; der Det/Stoch-Gap ist damit erstmals über den gesamten Verlauf sichtbar. Vertikale Linien: Phasenwechsel (dort wird jeweils das Bestmodell der Vorphase geladen; die x-Achse ist über die Phasen kumuliert). Erzeugt mit `scripts/plot_run_curve.py`.

Live-Monitoring-Redesign. Das WebSocket-Dashboard aus Etappe 2 wurde nach Dashboard- und Farb-Literatur überarbeitet (Abbildung 4): (a) Charts auf uPlot mit EMA-Glättung nach TensorBoard-Vorbild; (b) die SR-Kurve zeigt det. und stoch. getrennt — der zentrale Untersuchungsgegenstand war zuvor im Monitoring unsichtbar; (c) die Explorations-Heatmap wechselte von der Jet- auf die perzeptuell uniforme Viridis-Skala (Jet erzeugt künstliche Kontraste und ist nicht farbfeldsichten-tauglich); (d) die Agenten-Minimaps rekonstruieren aus dem gestreamten 15×15 -Sichtfeld eine wachsende Weltkarte (Wände, Bäume, Exit) statt nur der Agentenposition. Beim Umbau wurden zwei Fehler gefunden und behoben: Der Exit-Richtungspfeil war seit der Obs-Umstellung auf 229 Dimensionen stumm defekt, und der SB3-Stepzähler springt beim Phasenwechsel zurück (es wird das Bestmodell der Vorphase geladen), was unkorrigiert alle stepbasierten Zeitachsen verfälscht.

Seed-Replay-Analyse (Swarm vs. PLR). Das Training wiederholt seit Etappe 2 bei 30 % der Episoden-Resets einen bereits *gelösten* Seed („Erfolgs-Swarm“). Ein Literaturabgleich stellt diese Semantik in Frage: Prioritized Level Replay [7] zeigt, dass das Replay von Levels mit *hohem Lernpotenzial* — also gerade *nicht* gemeisterten — Sample-Effizienz und Test-Generalisierung verbessert; das Wiederholen gemeisteter Levels ist der Fehlermodus, den PLR behebt, und riskiert im Kontext des Projektziels (Generalisierung auf unbekannte Seeds) Layout-Memorierung. Da der 86 %-Referenzlauf jedoch *mit* Erfolgs-Swarm entstand, wird die Frage nicht per Meinung, sondern als A/B-Test entschieden (Erfolgs-Swarm vs. `--plr` vs. `--no-swarm`; Maßnahme B8 in `docs/BEWERTUNG_UND_PLAN.md`). Ein dabei entdeckter Designfehler wurde sofort behoben: Der Seed-Pool überlebte Phasenwechsel, obwohl ein „gelöster“ Seed nach dem Wechsel der Exit-Distanz eine andere Aufgabe beschreibt — der Pool wird jetzt bei jedem Phasenstart geleert.

5.6 Zeitleiste und Lessons Learned

Lessons Learned (negative Ergebnisse mit Erkenntniswert):

- *Visited-Mask in der Observation* destabilisiert den Argmax (jede 1-Bit-Änderung kann die Richtungspräferenz kippen).




Abbildung 4: Live-Monitoring (Demo mit Zufallsagenten): KPI-Zeile, Weltkarten-Minimaps (grau = Wand, blaugrau = erkundeter Boden, grün = Startpunkt) und uPlot-Charts. Im Training zusätzlich: goldene Raute = gesichteter Exit, grüner Blitz bei Exit-Erfolg, Viridis-Heatmap.

- *Naiver Curriculum-Transfer* zerstört die Vorgänger-Politik — Mixed-Distribution bzw. leistungsbasierte Phasenwechsel sind nötig.
- *Feature-Kodierung schlägt Feature-Auswahl*: Der BFS-Gradient war nie „zu schwach“ — er war falsch kodiert (Delta-Fix: Signal $32\times$ stärker).
- *Straf-Stacking* (Wand-, Loop-, Stagnations-Penalties) macht Stillstand lokal optimal; Information gehört in die Observation, nicht in den Reward.
- *Hyperparameter dominieren Features*: Alle v7-Feature-Ideen scheiterten an verstellten Basis-Hyperparametern; `ent_coef` war der entscheidende Faktor. Ohne das Changelog wäre die Root-Cause-Analyse (v2-Reverse-Engineering) nicht möglich gewesen.
- *Eval-Protokoll ist Teil des Experiments*: Data-Leakage über den Callback und das Gating auf einer signal-losen Metrik (det. SR bei hoher Entropie) verzerrten Selektion und Laufzeit unbemerkt.

6 Umgebungsrevision v11 (06.07.2026)

Eine systematische Überprüfung der Umgebung gegen Best Practices des Environment- und Reward-Designs führte zu sieben verifizierten Änderungen:

1. **Tote Features entfernt**: Energie und Inventar waren konstant; Observation 231 $\rightarrow$ 229 Dimensionen (Tabelle 1).
2. **Straf-Stacking entschärft**: Wand-Penalty entfernt, Loop-Penalty $-0.15 \rightarrow -0.05$ (Tabelle 2).
3. **Exit-Platzierung nach BFS-Laufweg**: Zuvor wurden Kandidaten nach *Luftlinie* gewählt — der reale Laufweg bei nominell „35–45“ streute auf 42–75 Tiles ($\varnothing$ 55). Nach dem Fix liegen alle 150 Eval-Seeds exakt im Sollbereich (Abbildung 5); das Curriculum steuert die Schwierigkeit damit erstmals präzise.

Datum	Meilenstein	Ergebnis (Testset A)
12.05.	Spiel-Engine & Weltgenerierung spielbar	—
16.05.	DQN-Fehlstart → PPO; BFS-Kraftfeld-Bug gefixt	Oracle 0/3 → 3/3
16.05.	Curriculum P1; naiver Transfer kollabiert → Mixed-Dist.	56 % → 86 % stoch
16.05.	Phase 4 (Reward-Tuning), 3-Läufe-Protokoll	98 % stoch / 2 % det
18.05.	Delta-BFS-Kodierung + Temperature-Sampling	100 % stoch / 42 % det
07.06.	RecurrentPPO ohne BFS-Orakel (Kernbeitrag)	86 % / 36 %
08.06.	POMDP-These; Callback-Bugs; Swarm/Live-Map	—
11.06.	Data-Leakage behoben (Val-Set 6000er); Lösbarkeit 100 %	—
13.–15.06.	v6–v9 scheitern → Root-Cause (ent_coef/batch/n_steps)	0–12 %
25.06.	v10-Reproduktion abgeschlossen (Referenzmodell)	86 % (Val)
06.07.	Env-Revision v11 (10 Änderungen); batch=64 validiert	52 % stoch @150k (P1)
07.07.	Erster v11-Gesamtlauf (Seed 0, läuft); Monitoring-Redesign; Swarm-Analyse (B8) + Pool-Fix	48 % stoch (P2, Val)
offen	v11-Lauf abschließen, Seeds 2–3, Swarm-A/B (B8), Det-Gap-Maßnahmen	—

Tabelle 6: Zeitleiste der RL-Entwicklung (Auswahl; vollständig in `CHANGELOG.md`). SR-Angaben je nach Etappe mit unterschiedlichem Protokoll — Werte vor dem 11.06. ohne strikte Val/Test-Trennung.

4. **Prozess-globales Config-Leck behoben:** Die Weltgenerierungs-Konfiguration ist im C++-Kern global; parallel existierende Umgebungen überschrieben sich gegenseitig (u. a. verschob der Eval-Callback die Phase-3-Trainingsverteilung unbemerkt). Jede Umgebung stempelt ihre Konfiguration nun bei jedem Reset neu.
5. **Mining/Bauen/Kampf aus dem RL-Pfad entfernt** (Binding erlaubt nur noch Aktionen 0–3; tote Reward-Terme gestrichen).
6. **Entropie-Annealing korrigiert:** stetig 0.05 → 0.001 statt Sprung 0.05 → 0.01 beim Phasenwechsel.
7. **Eval-Callback:** phasengerechtes Gating (Tabelle 3), Episoden-Caps pro Phase, Det+Stoch-Doppelmessung.

Alle Änderungen wurden einzeln verifiziert (Lösbarkeit 150/150, Oracle-Agent 10/10 mit exakt BFS-Distanz Schritten, Obs-Layout-Konsistenz, Ablehnung unzulässiger Aktionen). Da sich die Aufgabenverteilung dadurch ändert, sind Ergebnisse ab v11 als neue Baseline zu behandeln.

7 Performance-Analyse: Training beschleunigen

7.1 CPU schlägt Apple-GPU (MPS)

Ein kontrollierter Benchmark (identisches Trainings-Setup, 8192 Steps) zeigt: Die GPU ist für dieses kleine Netz (LSTM 256, 229 Inputs) in *jeder* Konfiguration langsamer als die CPU — der Kernel-Dispatch-Overhead pro Mini-Update übersteigt den Rechengewinn (Abbildung 6). Dies deckt sich mit der Empfehlung der SB3-Autoren, GPUs erst bei CNN-Politiken oder großen Netzen einzusetzen [6].




Abbildung 5: Wirkung der BFS-basierten Exit-Platzierung: tatsächliche Laufweg-Distanzen (min/Ø/max über je 50 Seeds) vor und nach dem Fix.




Abbildung 6: Training-FPS nach Device und Batch-Größe (RecurrentPPO, 16 Umgebungen, Apple M-Serie). MPS wurde für $\text{batch} \geq 128$ nicht weiter gemessen, da bereits bei 64 unterlegen.

7.2 Batch-Größe: 2,1-fache Beschleunigung, validiert

Mit `batch_size=8` fallen pro Rollout 5120 Gradient-Updates an — mehr Optimizer-Schritte als Umgebungsschritte. Da die Root-Cause-Analyse (Tabelle 5) die Batch-Größe nie isoliert getestet hatte, wurde ein Validierungslauf durchgeführt: 150k Phase-1-Steps mit `batch_size=64` (Abbildung 7). Ergebnis: gesunde Lernmetriken (`approx_kl` 0.01–0.06, `explained_variance` bis 0.72) und **52 % stochastische** / **22 % deterministische SR** nach nur 150k Steps — bei **187 statt 88 FPS**. Die Batch-Größe war demnach *nicht* der kritische v2-Erfolgsfaktor; `batch_size=64` wurde übernommen (Gesamtlaufzeit des Curriculums: ca. 2,5–3 h statt 5,5 h).

8 Einordnung in verwandte Arbeiten

Stoneforge liegt strukturell zwischen drei etablierten Benchmarks: MiniGrid (teilbeobachtbare Grid-Navigation, PPO+LSTM als Standard-Baseline) [8], Crafter (prozedural generiertes 2D-Survival-Spiel mit Mining und Crafting) [9] und Procgen (Generalisierung über prozedura-




Abbildung 7: Validierungslauf `batch_size=64` (Phase-1-Setup, Env v11): `approx_kl` deutlich über der Lernschwelle, `explained_variance` mit wiederkehrenden Hochphasen — die Politik lernt aktiv.

le Level) [1]. Publierte Zero-Shot-Ergebnisse auf prozeduralen Labyrinthen liegen typischerweise bei 25–53 % Success Rate; die hier erreichten 86 % (Test) bzw. 68 % (Holdout) bei nur 2,2 Mio. Trainingsschritten sind in diesem Kontext ein starkes Ergebnis. Für die Reduktion des Train/Test-Gaps ist Prioritized Level Replay [7] der vielversprechendste nächste Baustein; der vorhandene Seed-Pool-Mechanismus ist eine vereinfachte Variante davon.

9 Fazit und Ausblick

Stand: Die Machbarkeit ist gezeigt, beide Zielkriterien sind (stochastisch) erfüllt, die Umgebung ist nach der v11-Revision methodisch sauber (präzise Schwierigkeitssteuerung, policy-invariantes Shaping, kein Straf-Stacking, keine toten Features) und das Training ist doppelt so schnell.
Offene Schritte:

1. **v11-Curriculum-Lauf abschließen** (Seed 0 läuft seit 07.07., Abschnitt 5.5); danach Seeds 2–3 für Mittelwert $\pm$ Standardabweichung.
2. **Det/Stoch-Gap schließen:** (a) Temperatur-Sweep der Evaluation (wie viel Stochastik braucht die Politik?); (b) Self-Imitation — Nachtraining auf den eigenen erfolgreichen Episoden [10], um erfolgreiche Trajektorien in die Argmax-Politik zu überführen.
3. **Swarm-A/B-Test (B8):** Erfolgs-Swarm vs. `--plr` vs. `--no-swarm` — klärt datenbasiert, ob das Erfolgs-Seed-Replay hilft oder der PLR-Semantik [7] weichen sollte (Abschnitt 5.5).
4. **Falls Holdout B unter Ziel:** vollwertiges Prioritized Level Replay (TD-Error-gewichtet) [7].

Literatur

- [1] Karl Cobbe, Christopher Hesse, Jacob Hilton, and John Schulman. Leveraging procedural generation to benchmark reinforcement learning. In *International conference on machine learning*, pages 2048–2056. PMLR, 2020. <https://arxiv.org/abs/1912.01588>.
- [2] Sebastian Risi and Julian Togelius. Increasing generality in machine learning through procedural content generation. *Nature Machine Intelligence*, 2(8):428–436, 2020. <https://www.nature.com/articles/s42256-020-0208-5>.
- [3] Andrew Y Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*, pages 278–287, 1999.
- [4] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. <https://arxiv.org/abs/1707.06347>.
- [5] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [6] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021. <http://jmlr.org/papers/v22/20-1364.html>.
- [7] Minqi Jiang, Edward Grefenstette, and Tim Rocktäschel. Prioritized level replay. In *International Conference on Machine Learning (ICML)*, pages 4940–4950. PMLR, 2021. <https://arxiv.org/abs/2010.03934>.
- [8] Maxime Chevalier-Boisvert, Bolun Dai, Mark Towers, et al. Minigrid & miniworld: Modular & customizable reinforcement learning environments for goal-oriented tasks. *Advances in Neural Information Processing Systems*, 36, 2023. <https://arxiv.org/abs/2306.13831>.
- [9] Danijar Hafner. Benchmarking the spectrum of agent capabilities. *arXiv preprint arXiv:2109.06780*, 2021. <https://arxiv.org/abs/2109.06780>.
- [10] Junhyuk Oh, Yijie Guo, Satinder Singh, and Honglak Lee. Self-imitation learning. In *International Conference on Machine Learning (ICML)*, pages 3878–3887. PMLR, 2018. <https://arxiv.org/abs/1806.05635>.